СОГЛАСОВАННАЯ АРХИТЕКТУРА

Общая архитектура кредитного кабинета

Единый контракт, проверяемые границы и конкретные правила реализации.

20 октября 2026
Согласованная спецификация

Команда 3-5 человек
Окно 48-72 часа

Приложение не реализовано. Статические проверки документации и контрактов отделены от будущих испытаний runtime.

Связанные источники, контракты и приёмка доступны в Markdown-руководстве и общем index.html комплекта.

Согласованная редакция HACKATHON-1.5, 20 октября 2026 года. Это спецификация для разработки. Исполняемого приложения и результатов его испытаний в комплекте нет.

Уточнение объёма от 21.10.2026: реализован standalone ML-срез (risk, PostgreSQL snapshots/inference, сценарии и передача интеграторам). UI/backend-процесс и остальные ML-функции ниже сохраняют проектный статус. Команды запуска и контракты среза: docs/ml-integration.md корня приложения.

1. Продукт и критерии успеха

Пользователь - представитель малого бизнеса, оформляющий финансирование от имени компании. Кабинет должен уменьшать повторный ввод и неопределённость: что принято, чего не хватает, что происходит и что делать дальше. Банковская сторона получает сохранённые версии данных, управляемый запрос уточнений и объяснимую модель принятия решения.

Обязательный путь: вход → диагностика потребности → пригодные продукты → заявка → подтверждение финансов → отправка → обработка → уточнение при необходимости → результат → принятие условий → моделируемое оформление. Самостоятельный web-путь не требует SMS, звонка или электронной почты.

Демонстрируем три синтетических продукта: оборотный кредит, кредитная линия, овердрафт. Это не действующие условия Альфа-Банка. Предварительный расчёт не является офертой, рекомендация не является обещанием одобрения.

Основные продуктовые метрики: завершение заявки, время до отправки, восстановление черновика, завершение RFI без новой заявки и понимание следующего действия. До пользовательского исследования численные цели - гипотезы. Считать funnel по событиям start/save/submit/RFI/response/offer/acceptance/completion; клики и скорость ответа ML не заменяют завершение процесса. Не заявлять рост конверсии или сокращение банковских потерь без baseline и эксперимента.

2. Единая архитектура и три профиля

local-mvp: web + модульное Java-приложение + PostgreSQL + Python ML + локальный llama-server + scanner. Web reverse proxy и SPA находятся в одном контейнере. Банковский симулятор, файловые streaming-маршруты и dispatcher - изолированные модули Java-приложения, а не отдельные микросервисы. OCR worker - отдельный процесс того же ML-образа; задания арендуются через API. Named volumes хранят PostgreSQL, quarantine/clean и версии моделей.

bank-target: штатные IAM/WAF/gateway, управляемые PostgreSQL/Kafka/Redis/S3, Kubernetes, отдельный файловый gateway и банковский адаптер, наблюдаемость и управляемая ML-платформа. Выделение процессов выполняется по измеренной нагрузке и независимому масштабированию, а не по количеству таблиц.

Все названные технологии остаются архитектурными компонентами уже в MVP. Каждый имеет порт или эксплуатационную границу, владельца и локальный заменитель. Qdrant заменяется реальным NumPy-поиском, Redis - JDBC-сессиями и локальным TTL-кешем, Feast - immutable feature repository. Airflow/MLflow/Evidently имеют offline-job/registry/quality адаптеры. Это не эмуляция полных сервисов. **local-integrations** дополнительно подключает выбранные настоящие Redis-cache/Qdrant/MLflow; готовность каждого подтверждается отдельно. Полный mapping и ограничения - в общем руководстве по адаптерам.

3. Владельцы и границы

Область	Владелец	Запрещённая подмена
Сессия и полномочия	Access, в production IAM банка	Клиент не назначает компанию и роль самостоятельно
Каталог и eligibility	Catalog + владелец продукта	Ранжировщик не добавляет непригодный продукт
Черновик и отправленные данные	Applications	Отправленный снимок не редактируется через PATCH
Согласия	Consents	Доступ к компании не даёт права согласиться за любого субъекта
Файлы и подтверждение OCR	Documents + Applications	Confidence не является подтверждением клиента
Рассмотрение и решение	Bank simulator; в target кредитный конвейер	ML не пишет APPROVED/DECLINED в заявку
Статус, next action, лента	Workspace	Статья не заменяет обязательное уточнение
Предложение и оформление	Bank simulator; в target банк	UI не объявляет деньги выданными без события
Источники RAG	KB authority в backend	Векторный индекс не определяет права публикации
Артефакты и inference record	ML, отдельная роль хранения	Прогноз нельзя отвязать от версии и данных

Монолит не отменяет границ: модули взаимодействуют через application interfaces и события, не импортируют чужие repositories. Общими бывают технические типы; общей изменяемой бизнес-сущности между модулями нет. Python не пишет напрямую в таблицы заявок/решений.

4. Данные и надёжность

Одновременно с командой сервер фиксирует idempotency record, новый бизнес-объект/снимок, operation и outbox. 202 выдаётся только после commit. Dispatcher доставляет сообщения хотя бы один раз; consumer фиксирует inbox и бизнес-эффект одной транзакцией. Это не обещание exactly-once доставки.

Идемпотентный ключ ограничен actor/company/operation type, хранится 7 дней вместе с нормализованным hash тела и результатом. Правильный повтор возвращает исходный ответ до проверки нового состояния; то же имя ключа с другим телом - 409. По истечении срока повтор финансово значимого действия требует сверки, а не нового слепого вызова.

Версии независимы: Application.version/ETag, RFI requestVersion, InformationDraft.draftVersion, financial statementVersion, requirementsVersion, objectVersion, caseVersion и viewVersion. Не использовать время обновления вместо CAS. Отправка и ответ на RFI закрепляют точные documentReferences и серверный финансовый снимок.

Решения и переходы полностью перечислены в contracts/state-machine.json. Канонический публичный API содержит 60 операций; demo-входы изолированы в отдельном контракте. Проект не имеет действующих потребителей: переход с 1.2/1.3-design на 1.4-design выполняется одним согласованным изменением, а не имитацией поддержки legacy-клиентов.

5. Масштабирование и ограничения

Расчётная исходная гипотеза target: 10 тыс. активных клиентов × 0,1 запроса/с = 1 тыс. RPS; пик 50 тыс. = 5 тыс. RPS. SSE и загрузки считаются отдельно. Эта арифметика не доказывает достаточность оборудования: проверяются DB IOPS, размер записей/файлов, конкуренция, skew по компаниям и длительность запросов.

Первый предел - PostgreSQL и конкуренция обработки, а не отсутствие микросервисов. Ввести индексы company/application/status/time, keyset pagination, bounded pools и очереди; измерять p95 и возраст outbox. Реплики HTTP требуют общих сессий, stream journal и object storage. Локальный filesystem не является общим томом для нескольких узлов.

Для target сохраняются проектные цели: доступность 99,95%/месяц, p95 чтений ≤300 мс, локальных команд ≤500 мс, свежесть проекции p95 ≤5 с; RPO ≤5 мин/RTO ≤30 мин, три домена отказа. Для MVP нет заявления о достижении этих значений. Бюджеты CPU ML находятся отдельно в contracts/runtime-policy.json.

Kafka/Redis/S3/Feast/Airflow закреплены через порты с начала разработки; локальная реализация сохраняет обязательные инварианты. Настоящие сервисы выбираются конфигурацией после проверки совместимости и поведения при сбое. Kafka сохраняет outbox/inbox; Redis разделяет сессии и кеш; S3 хранит точные версии; Feast разделяет online/historical retrieval; Airflow не обучает модель в клиентском запросе. Подключение контейнера без выбранного SDK-адаптера не считается завершённой интеграцией.

6. Безопасность и допуск

В local-mvp все данные искусственные; тестовый вход явно помечен. Cookie HttpOnly/SameSite, CSRF, серверная проверка tenant/role и запрет публичного доступа к внутренним портам обязательны. HTTPS обязателен для внешнего показа; localhost допускает development cookie без Secure. Режим production не разрешает этот override.

Секреты не передаются в браузер и не лежат в Git. Внутренние сервисы используют отдельные ролевые токены в изолированной сети, target - workload identity/mTLS. AV работает fail closed; EICAR/ошибка scanner не становятся CLEAN. Модели и документы не отправляются в публичные API. Идентификаторы и hashes не являются достаточным обезличиванием.

Перед банковским пилотом нужны G01-G08: протокол IAM/полномочий; банковские команды и исходы; право/политика обработки данных; хранение/ключи/retention; лицензии и supply chain; восстановление и полный журнал принятых внешних команд; измеренные SLO/ёмкость; валидация моделей и продуктовых правил. До завершения DR-сверки финансово значимые команды запрещены. Поиск только по сохранившимся локальным ключам не восстанавливает потерянные при RPO команды.

Эти условия - инженерный план допуска, не юридическое заключение и не подтверждение соответствия нормативам.

Технологические адаптеры

Именованный стек и выбранный runtime отражаются раздельно: intended technology, selected adapter и evidence. Неизвестный provider останавливает запуск; автоматическая смена authority запрещена. Каталог интерфейсов обязателен для всех направлений.